Univerzitet u Sarajevu

Elektrotehnički fakultet

Simulacija toplotne razmjene između tijela

Seminarski rad

Student:

Irma Topčagić

Profesorica:

prof. dr Razija Turčinhodžić

Sadržaj

1 Uvod **3**

2 Teorijska osnova procesa toplotne razmjene **4**

2.1 Termodinamički zakoni 5

2.2 Toplotna provodnost materijala 5

2.3 Osnovni koncepti toplotne razmjene 6

3 Fizikalna interpretacija simulacije toplotne razmjene između tijela **7**

3.1 Fizički opis procesa 7

3.2 Smjer prenosa toplote i uspostavljanje ravnoteže 8

3.3 Uloga mase i toplotnog kapaciteta 8

3.4 Vremenski tok promjene temperature 9

4 Idealizacija i pretpostavke matematičkog modela **9**

4.1 Pretpostavka homogenosti temperature tijela 10

4.2 Zatvoren sistem i zanemarivanje gubitaka 10

4.3 Konstantni fizički parametri 11

4.4 Dominantni mehanizam prenosa toplote 11

4.5 Zanemarivanje faznih promjena i mehaničkih efekata 11

4.6 Ograničenja modela i značaj idealizacije 11

5 Matematički model toplotne razmjene između dva tijela **12**

5.1 Energetski bilans i osnovne veličine 12

5.2 Izvođenje sistema diferencijalnih jednačina 13

5.3 Početni uslovi 14

5.4 Ravnotežna temperatura i očuvanje energije 14

5.5 Jednačina za temperaturnu razliku i vremenska konstanta 14

5.6 Matrični zapis sistema 15

6 Numeričke metode rješavanja matematičkog modela **16**

6.1 Diskretizacija vremena 16

6.2 Eksplicitna Eulerova metoda 16

6.3 Heunova metoda (poboljšana Eulerova metoda) 17

6.4 Runge–Kutta metoda četvrtog reda 17
6.5 Stabilnost i izbor vremenskog koraka 18

7 Implementacija simulacije **18**
7.1 Modul `model.py`: fizički model i analitičko rješenje 19
7.2 Modul `numerical_methods.py`: Euler, Heun i RK4 20
7.2.1 Eulerova metoda (metoda prvog reda) 20
7.2.2 Heunova metoda (poboljšani Euler, metoda drugog reda) 21
7.2.3 Runge–Kutta metoda četvrtog reda (RK4) 21
7.3 Modul `simulation.py`: simulacioni algoritam i računanje greške 21
7.4 Modul `visualization.py`: grafički prikaz rezultata 22
7.5 Modul `scenarios.py`: definisanje fizičkih scenarija 23
7.6 Modul `analysis.py`: analiza greške i vremena izvršavanja 26
7.7 Glavni program `main.py` 26

8 Analiza rezultata **27**
8.1 Scenario A: Simetrične toplotne mase ($C_1 = C_2$) 27
8.2 Scenario B: Velika razlika toplotne mase ($C_1 \gg C_2$) 30
8.3 Scenario C: Slaba termička veza (mali K) 33
8.4 Scenario D: Jednake toplotne mase, velika početna razlika temperatura . . 34
8.5 Poređenje scenarija: vrijeme do termičke ravnoteže 36
8.6 Poređenje grešaka 37

9 Zaključak **38**

A Dodatak: Kodovi **40**

1 Uvod

Toplotna razmjena predstavlja jedan od temeljnih fizičkih procesa koji se neprekidno odvija kako u prirodnim, tako i u tehničkim i inženjerskim sistemima. Svaki sistem u kojem postoji temperaturna razlika između njegovih dijelova ili između sistema i okoline podložan je procesu prenosa toplote. Primjeri ovakvih procesa mogu se pronaći u svakodnevnom životu, kao što su zagrijavanje vode u posudi, hlađenje metala izloženog okolnom zraku, regulacija tjelesne temperature kod živih organizama, ali i u složenim tehničkim sistemima poput termoenergetskih postrojenja, sistema grijanja i klimatizacije, elektronskih uređaja i industrijskih proizvodnih procesa. Razumijevanje zakonitosti toplotne razmjene od izuzetnog je značaja u oblastima fizike, mašinstva, elektrotehnike, energetike i klimatologije, gdje pravilno upravljanje toplotnim procesima direktno utiče na efikasnost, sigurnost i pouzdanost sistema [1].

Analitičko rješavanje problema toplotne razmjene često je otežano zbog složenosti realnih sistema, nelinearnosti fizičkih zakona i međusobnog uticaja velikog broja parametara. Zbog toga se u savremenom inženjerskom pristupu sve češće koriste matematički modeli i računarske simulacije koje omogućavaju detaljno proučavanje ponašanja sistema u vremenu. Simulacija toplotne razmjene omogućava praćenje promjene temperature tijela, analizu uspostavljanja toplotne ravnoteže, kao i ispitivanje uticaja različitih fizičkih parametara na dinamiku procesa.

U okviru ovog seminarskog rada bit će razmatrana simulacija toplotne razmjene između dva tijela različitih početnih temperatura u pojednostavljenom zatvorenom sistemu. Poseban naglasak stavljen je na formulaciju matematičkog modela zasnovanog na zakonima termodinamike, kao i na njegovo numeričko rješavanje pomoću računarskih metoda. Za implementaciju simulacije odabran je programski jezik Python, koji se sve češće koristi u naučnim i inženjerskim primjenama zbog svoje jednostavnosti, čitljivosti i bogatog skupa biblioteka namijenjenih numeričkom računanju i vizualizaciji podataka.

Pored same implementacije simulacije, pažnja će biti posvećena i analizi dobijenih rezultata, poređenju različitih numeričkih metoda i razmatranju fizičkog značenja simuliranih procesa. Na taj način, ovaj rad ima za cilj da poveže teorijske osnove toplotne razmjene sa praktičnom primjenom računarskih metoda u okviru računarskog modeliranja i simulacije.

2 Teorijska osnova procesa toplotne razmjene

Toplotna razmjena predstavlja proces prenosa energije između tijela ili sistema usljed razlike u njihovim temperaturama.[1] Ovaj proces je spontan i uvijek se odvija u smjeru od tijela više temperature prema tijelu niže temperature. Toplotna razmjena prestaje kada sva tijela u sistemu dostignu istu temperaturu, odnosno kada se uspostavi toplotna ravnoteža. Važno je napomenuti da toplota nije isto što i temperatura — toplota je energija koja se prenosi, dok je temperatura mjera koliko su čestice tijela brze u svom kretanju.

Toplota se uvijek prenosi, odnosno ne zadržava se u tijelu. Tijelo posjeduje unutrašnju energiju, a toplota je samo ona energija koja se prenosi zbog temperaturne razlike.

Prije nego što se detaljnije počnemo baviti simulacijom, važno je razumjeti osnovne pojmove vezane za toplotnu razmjenu: [1]

- **Toplota (Q)** – energija koja se prenosi između tijela zbog razlike u temperaturi. Mjeri se u džulima (J).
- **Temperatura (T)** – mjera prosječne kinetičke energije čestica u tijelu. Jedinica: kelvin (K) ili stepeni Celzijusa (°C).
- **Toplotni kapacitet (C)** – količina toplote potrebna da se temperatura tijela poveća za jedan stepen:
$$C = \frac{Q}{\Delta T}$$
- **Specifični toplotni kapacitet (c)** – količina toplote potrebna da se 1 kg materijala zagrije za 1°C:
$$Q = mc\Delta T$$
pri čemu je m masa tijela.
- **Toplotna ravnoteža** – stanje kada tijela koja su u kontaktu više ne razmjenjuju toplotu i imaju istu temperaturu.

Razumijevanje osnovnih pojmova[1] omogućava jasnije definisanje procesa simulacije i primjenu odgovarajućih matematičkih modela.

2.1 Termodinamički zakoni

Toplotna razmjena se temelji na zakonima termodinamike koji postavljaju fundamentalne principe ponašanja energije u fizičkim sistemima.

Prvi zakon termodinamike, poznat i kao zakon očuvanja energije, kaže da se energija ne može stvoriti niti uništiti, već samo pretvoriti iz jednog oblika u drugi.[3] U kontekstu toplotne razmjene, ovo znači da toplota koju jedno tijelo izgubi mora biti jednaka toploti koju drugo tijelo primi, pod uslovom da nema gubitaka u okolinu. Matematički se ovo može izraziti kao:

$$Q_{\text{predato}} + Q_{\text{primljeno}} = 0$$

Drugi zakon termodinamike uvodi koncept entropije i usmjerenosti prirodnih procesa. Ovaj zakon nam govori da toplota spontano teče od toplijeg tijela prema hladnijem, nikada obrnuto. Upravo zbog ovog zakona, kada dva tijela različitih temperatura dođu u kontakt, dolazi do izjednačavanja temperatura.[3] Proces se nastavlja sve dok se ne postigne termodinamička ravnoteža, odnosno stanje maksimalne entropije sistema.

Nulti zakon termodinamike, iako numerički označen kao "nulti", fundamentalan je za razumijevanje koncepta temperature. Ovaj zakon kaže, da ako su dva tijela u toplotnoj ravnoteži s trećim tijelom, tada su i međusobno u toplotnoj ravnoteži.[3] Ovo nam omogućava da definišemo temperaturu kao objektivnu veličinu koja se može mjeriti.

2.2 Toplotna provodnost materijala

Različiti materijali imaju različitu sposobnost provođenja toplote, što se kvantificira koeficijentom toplotne provodnosti k. Metali poput bakra i aluminija imaju visoke vrijednosti koeficijenta provodnosti, što ih čini odličnim provodnicima toplote. S druge strane, materijali poput drveta, stakla ili plastike imaju niske vrijednosti ovog koeficijenta i smatraju se toplotnim izolatorima.

Toplotna provodnost zavisi od unutrašnje strukture materijala. Kod metala, slobodni elektroni omogućavaju brz prenos energije, dok kod izolatora prenos toplote zavisi isključivo od vibracija atoma u kristalnoj rešetki, što je znatno sporiji proces.

2.3 Osnovni koncepti toplotne razmjene

Toplotna razmjena se događa zbog razlike u temperaturi između tijela i teži uspostavljanju **toplotne ravnoteže**. Glavni mehanizmi prenosa toplote su:[5]

1. **Toplotna provodnost (kondukcija)** – proces prenosa toplote kroz sam materijal, bez fizičkog pomjeranja njegovih dijelova. Matematički se opisuje Furijeovim zakonom:

   $$Q = -kA\frac{dT}{dx}$$

   gdje je Q količina toplote, k koeficijent provodnosti materijala, A površina kroz koju toplota prolazi, a $\frac{dT}{dx}$ temperaturni gradijent.

2. **Konvekcija** – prenos toplote koji nastaje kretanjem fluida (vazduh, voda i sl.) Jednostavan opis daje Njutnov zakon hlađenja:

   $$Q = hA(T_{\text{tijelo}} - T_{\text{okolina}})$$

   gdje je h koeficijent konvekcije.

3. **Radijacija (zračenje)** – prenos toplote u obliku elektromagnetnog zračenja. Može se opisati Stefan-Boltzmannovim zakonom:

   $$Q = \epsilon\sigma A(T^4 - T^4_{\text{okolina}})$$

   gdje je ϵ emisivnost površine, σ Stefan-Boltzmannova konstanta.

Ovi modeli predstavljaju osnovu za razumijevanje i simulaciju realnih procesa toplotne razmjene. Primjenom navedenih fizičkih zakonitosti i matematičkih izraza moguće je precizno pratiti promjene temperature u vremenu i analizirati ponašanje različitih sistema.

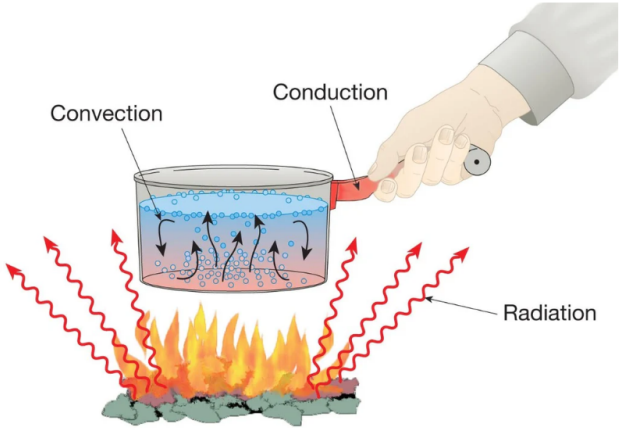

Slika 1: Ilustracija osnovnih mehanizama prenosa toplote

3 Fizikalna interpretacija simulacije toplotne razmjene između tijela

Toplotna razmjena između tijela predstavlja spontani proces prenosa energije koji nastaje isključivo zbog razlike u temperaturi. U posmatranom problemu razmatraju se dva tijela različitih početnih temperatura $T_1(0)$ i $T_2(0)$ koja se nalaze u međusobnom toplotnom kontaktu.

3.1 Fizički opis procesa

U trenutku uspostavljanja kontakta između tijela, čestice toplijeg tijela posjeduju veću prosječnu kinetičku energiju u odnosu na čestice hladnijeg tijela. Prilikom njihovih međusobnih sudara dolazi do prenosa energije. Kao posljedica ovog procesa, toplije tijelo gubi dio svoje unutrašnje energije, dok hladnije tijelo prima energiju i zagrijava se.
Važno je naglasiti da se u ovom procesu ne prenosi temperatura, već toplota kao oblik energije. Promjena temperature tijela direktna je posljedica promjene njegove unutrašnje energije. Ovaj proces je u skladu sa drugim zakonom termodinamike, koji određuje prirodni smjer prenosa toplote. [5]

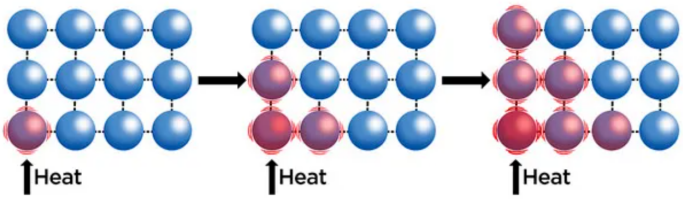

Slika 2: Mikroskopski prikaz prenosa energije sa toplijeg na hladnije tijelo.

3.2 Smjer prenosa toplote i uspostavljanje ravnoteže

Prema drugom zakonu termodinamike, toplota se spontano prenosi isključivo sa tijela više temperature na tijelo niže temperature. Proces razmjene toplote se nastavlja sve dok razlika temperatura između tijela ne nestane, odnosno dok se ne ispuni uslov:

$$T_1(t) = T_2(t) = T_{\text{eq}}$$

gdje je T_{eq} ravnotežna temperatura sistema. U trenutku kada se dostigne toplotna ravnoteža, prestaje daljnji prenos toplote jer ne postoji temperaturna razlika koja bi ga pokretala. Ovakvo stanje predstavlja stabilno stanje sistema.

3.3 Uloga mase i toplotnog kapaciteta

Brzina promjene temperature svakog tijela ne zavisi samo od temperaturne razlike, već i od njegovog toplotnog kapaciteta.

Tijelo sa većim toplotnim kapacitetom zahtijeva veću količinu toplote da bi mu se temperatura promijenila za isti iznos. Zbog toga tijela veće mase ili napravljena od materijala sa većim specifičnim toplotnim kapacitetom sporije mijenjaju temperaturu u odnosu na tijela sa manjim toplotnim kapacitetom. Ovaj efekat ima značajan uticaj na dinamiku procesa i jasno se može uočiti u numeričkoj simulaciji.

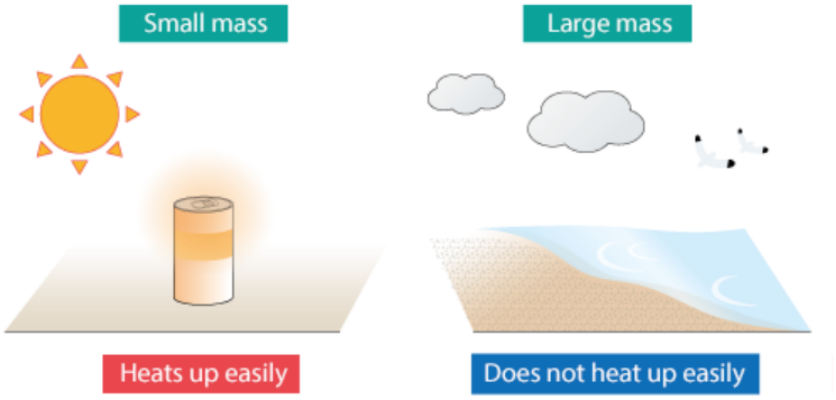

Slika 3: Ilustrativni prikaz uticaja toplotne mase na promjenu temperature

3.4 Vremenski tok promjene temperature

U idealiziranom slučaju, brzina prenosa toplote proporcionalna je trenutnoj razlici temperatura između tijela:

$$\dot{Q} \propto (T_1 - T_2)$$

Na početku procesa, kada je temperaturna razlika velika, prenos toplote je intenzivan i promjene temperature su brze. Kako se temperature tijela približavaju, razlika postaje sve manja, što uzrokuje postepeno usporavanje procesa.
Zbog ovakvog ponašanja, promjena temperature u vremenu često ima eksponencijalni karakter. Sistem se brzo približava ravnoteži, ali potpuno izjednačavanje temperatura se u idealnom modelu ostvaruje asimptotski.

4 Idealizacija i pretpostavke matematičkog modela

Prije formulisanja matematičkog modela toplotne razmjene između tijela, neophodno je izvršiti odgovarajuću idealizaciju realnog fizičkog sistema. Realni sistemi često su izuzetno složeni i uključuju veliki broj međusobno povezanih fizičkih procesa, što analitičko i numeričko modeliranje čini vrlo zahtjevnim. Zbog toga se uvode pojednostavljenja i pretpostavke koje omogućavaju formiranje matematičkog modela, a da se pritom zadrži fizička suština posmatranog procesa.

U ovom radu razmatra se pojednostavljeni model toplotne razmjene koji je dovoljno realističan da opiše osnovnu dinamiku procesa, ali i dovoljno jednostavan da se može efikasno simulirati korištenjem numeričkih metoda.

4.1 Pretpostavka homogenosti temperature tijela

Jedna od osnovnih pretpostavki matematičkog modela jeste da je temperatura unutar svakog tijela u svakom trenutku prostorno uniformna. Drugim riječima, zanemaruje se postojanje unutrašnjih temperaturnih gradijenata unutar tijela. Ovakav pristup poznat je kao model sa koncentrisanim parametrima (engl. *lumped parameter model*)[1].
Ova pretpostavka je fizički opravdana u slučajevima kada tijela imaju relativno male dimenzije, visoku toplotnu provodnost ili kada je unutrašnje izjednačavanje temperature znatno brže u odnosu na razmjenu toplote između tijela. Kao rezultat toga, svako tijelo može se opisati jednom vremenski zavisnom temperaturom, $T_1(t)$ i $T_2(t)$, što značajno pojednostavljuje matematičku formulaciju problema.

4.2 Zatvoren sistem i zanemarivanje gubitaka

U osnovnom modelu pretpostavlja se da sistem čine isključivo dva tijela koja razmjenjuju toplotu međusobno, bez gubitaka energije u okolinu. To znači da se sistem smatra zatvorenim, te da važi zakon očuvanja energije:

$$Q_1 + Q_2 = 0$$

gdje Q_1 predstavlja količinu toplote koju prvo tijelo izgubi, a Q_2 količinu toplote koju drugo tijelo primi.
Ova pretpostavka omogućava direktnu primjenu prvog zakona termodinamike i pojednostavljuje energetski bilans sistema. U realnim uslovima, određeni gubici prema okolini su neizbježni, ali se u okviru ovog rada oni zanemaruju radi jasnije analize osnovnog mehanizma toplotne razmjene. U kasnijim proširenjima modela, ovi efekti mogu se dodatno uključiti.

4.3 Konstantni fizički parametri

Dalja važna pretpostavka jeste da su fizički parametri sistema konstantni tokom vremena. To podrazumijeva da su:

- mase tijela m_1 i m_2 konstantne,
- specifični toplotni kapaciteti c_1 i c_2 konstantni,
- koeficijent prenosa toplote K između tijela konstantan.

U stvarnosti, ovi parametri mogu zavisiti od temperature, ali se za umjerene temperaturne promjene njihova zavisnost može zanemariti bez značajnog gubitka tačnosti.

4.4 Dominantni mehanizam prenosa toplote

U okviru posmatranog sistema pretpostavlja se da je dominantni mehanizam prenosa toplote kondukcija. Time se zanemaruju efekti konvekcije i radijacije, koji su u određenim uslovima znatno slabiji ili se mogu obuhvatiti kroz efektivni koeficijent prenosa toplote.
Na ovaj način, prenos toplote može se aproksimirati proporcionalnošću temperaturne razlike između tijela, što predstavlja osnovu za dalju matematičku formulaciju.

4.5 Zanemarivanje faznih promjena i mehaničkih efekata

U modelu se pretpostavlja da tokom procesa razmjene toplote ne dolazi do faznih promjena materijala, kao što su topljenje ili isparavanje. Također se zanemaruju mehanički efekti, promjene zapremine i deformacije tijela usljed temperaturnih promjena.
Ove pretpostavke omogućavaju da se proces razmjene toplote posmatra isključivo kao problem promjene unutrašnje energije tijela, bez dodatnih složenih spregnutih efekata.

4.6 Ograničenja modela i značaj idealizacije

Iako uvedene pretpostavke ograničavaju primjenjivost modela na idealizirane uslove, one omogućavaju jasno razumijevanje osnovnih principa toplotne razmjene i efikasnu primjenu numeričkih metoda. Upravo ovakav pristup predstavlja osnovu računarskog modeliranja, gdje se složeni realni sistemi aproksimiraju pojednostavljenim modelima koji zadržavaju ključna fizička svojstva procesa.[6]

5 Matematički model toplotne razmjene između dva tijela

Na osnovu fizičke interpretacije i uvedenih pretpostavki, moguće je formulisati matematički model procesa toplotne razmjene između dva tijela. Model se zasniva na energetskom bilansu i prvom zakonu termodinamike.

5.1 Energetski bilans i osnovne veličine

Neka su:

- m_1, m_2 mase tijela,
- c_1, c_2 specifični toplotni kapaciteti materijala,
- $T_1(t)$, $T_2(t)$ temperature tijela u trenutku t,
- $C_1 = m_1 c_1,\ C_2 = m_2 c_2$ toplotni kapaciteti tijela, koji predstavljaju mjeru njihove toplotne mase u okviru inženjerskog modeliranja sistema.

Promjena unutrašnje energije svakog tijela (pri konstantnom c i bez mehaničkog rada) može se aproksimirati izrazom:

$$dU_i = m_i c_i \, dT_i = C_i \, dT_i, \qquad i \in \{1, 2\}.$$

U zatvorenom sistemu, toplota koju jedno tijelo izgubi jednaka je toploti koju drugo tijelo primi:

$$dQ_1 + dQ_2 = 0.$$

Kako su $dQ_i = dU_i$ (nema rada i nema gubitaka), slijedi:

$$C_1 \, dT_1 + C_2 \, dT_2 = 0,$$

odnosno, u diferencijalnom obliku:

$$C_1 \frac{dT_1}{dt} + C_2 \frac{dT_2}{dt} = 0.$$

Ovaj izraz predstavlja matematičku formulaciju očuvanja energije unutar sistema.

Za idealizovani kontakt, tok toplote između tijela se može modelirati proporcionalno trenutnoj temperaturnoj razlici:

$$\dot{Q} = k\,(T_1 - T_2),$$

gdje je $k > 0$ efektivni koeficijent prenosa toplote (u jedinicama W/K). Ovaj koeficijent obuhvata uticaj kontaktne površine, termičkog otpora na spoju i provodnosti materijala, te predstavlja pojednostavljenu ali vrlo korisnu aproksimaciju u okviru modela sa koncentrisanim parametrima.
Smjer toka toplote je takav da toplota prelazi sa toplijeg ka hladnijem tijelu. Ako je $T_1 > T_2$, tada je $\dot{Q} > 0$ i energija se prenosi iz tijela 1 u tijelo 2.

5.2 Izvođenje sistema diferencijalnih jednačina

Tok toplote koji tijelo 1 predaje jednak je negativnoj promjeni njegove energije po jedinici vremena:

$$\dot{Q}_1 = -\frac{dU_1}{dt} = -C_1\frac{dT_1}{dt}.$$

Istovremeno, tijelo 2 prima toplotu:

$$\dot{Q}_2 = \frac{dU_2}{dt} = C_2\frac{dT_2}{dt}.$$

Kako je $\dot{Q}_1 = \dot{Q}_2 = \dot{Q}$, uz $\dot{Q} = k(T_1 - T_2)$ dobija se sistem:

$$C_1\frac{dT_1}{dt} = -k(T_1 - T_2),$$

$$C_2\frac{dT_2}{dt} = \quad k(T_1 - T_2).$$

Ovo je osnovni matematički model (sistem linearnih diferencijalnih jednačina prvog reda) koji opisuje dinamiku izjednačavanja temperatura dva tijela.

5.3 Početni uslovi

Za kompletno definisan problem potrebno je zadati početne uslove:

$$T_1(0) = T_{1,0}, \qquad T_2(0) = T_{2,0}.$$

Numerička simulacija zatim računa razvoj $T_1(t)$ i $T_2(t)$ za $t > 0$.

5.4 Ravnotežna temperatura i očuvanje energije

U stanju ravnoteže važi $T_1 = T_2 = T_{\text{eq}}$. Ravnotežna temperatura se može dobiti direktno iz očuvanja energije. Ukupna energija sistema (u ovom modelu) ostaje konstantna:

$$C_1 T_1(t) + C_2 T_2(t) = C_1 T_{1,0} + C_2 T_{2,0}.$$

U ravnoteži:

$$(C_1 + C_2) T_{\text{eq}} = C_1 T_{1,0} + C_2 T_{2,0},$$

pa je:

$$T_{\text{eq}} = \frac{C_1 T_{1,0} + C_2 T_{2,0}}{C_1 + C_2}.$$

Ovaj rezultat ima jasnu fizičku interpretaciju: ravnotežna temperatura dobija se kao srednja vrijednost početnih temperatura, pri čemu veći toplotni kapacitet tijela ima veći uticaj na konačnu temperaturu.

5.5 Jednačina za temperaturnu razliku i vremenska konstanta

Definišimo temperaturnu razliku:

$$\Delta T(t) = T_1(t) - T_2(t).$$

Oduzimanjem jednačina sistema dobija se:

$$\frac{d}{dt}(T_1 - T_2) = -k \left(\frac{1}{C_1} + \frac{1}{C_2} \right) (T_1 - T_2),$$

odnosno:

$$\frac{d\Delta T}{dt} = -\lambda \, \Delta T, \qquad \lambda = k \left(\frac{1}{C_1} + \frac{1}{C_2} \right).$$

Rješenje sistema diferencijalnih jednačina ima eksponencijalni karakter, što je tipično za linearne sisteme prvog reda. [7]

$$\Delta T(t) = \Delta T(0)\, e^{-\lambda t}.$$

Često se uvodi vremenska konstanta procesa:

$$\tau = \frac{1}{\lambda} = \frac{1}{k\left(\frac{1}{C_1} + \frac{1}{C_2}\right)} = \frac{C_1 C_2}{k(C_1 + C_2)}.$$

Vremenska konstanta τ opisuje brzinu izjednačavanja temperatura: veći k znači brži prenos toplote (manja τ), dok veći toplotni kapaciteti znače sporiji proces (veća τ).

5.6 Matrični zapis sistema

Sistem se može zapisati i u kompaktnom matričnom obliku, što je korisno za analizu stabilnosti i primjenu numeričkih metoda. Neka je:

$$\mathbf{T}(t) = \begin{bmatrix} T_1(t) \\ T_2(t) \end{bmatrix}.$$

Tada se sistem može napisati kao:

$$\frac{d\mathbf{T}}{dt} = \mathbf{A}\mathbf{T},$$

gdje je matrica:

$$\mathbf{A} = \begin{bmatrix} -\frac{k}{C_1} & \frac{k}{C_1} \\ \frac{k}{C_2} & -\frac{k}{C_2} \end{bmatrix}.$$

Ovaj zapis je posebno pogodan za poređenje numeričkih metoda i razumijevanje dinamike sistema (npr. svojstvene vrijednosti matrice $\mathbf{A}$ određuju karakteristično ponašanje sistema).

6 Numeričke metode rješavanja matematičkog modela

Za numeričko rješavanje sistema korištene su standardne inženjerske metode opisane u literaturi. [4, 8] Poseban akcenat stavljen je na njihovu tačnost, stabilnost i pogodnost za implementaciju u programskom jeziku Python.

6.1 Diskretizacija vremena

Osnovna ideja numeričkog rješavanja diferencijalnih jednačina sastoji se u diskretizaciji kontinuirane vremenske ose. Vremenski interval simulacije $[0, T_{\max}]$ dijeli se na N jednakih podintervala dužine:

$$\Delta t = \frac{T_{\max}}{N}.$$

Vrijednosti temperatura se tada računaju u diskretnim vremenskim trenucima:

$$t_n = n\Delta t, \qquad n = 0, 1, 2, \ldots, N.$$

Cilj numeričke metode jeste da, polazeći od poznatih početnih uslova $T_1(0)$ i $T_2(0)$, aproksimira temperature $T_1(t_n)$ i $T_2(t_n)$ u svakom narednom vremenskom koraku.

6.2 Eksplicitna Eulerova metoda

Najjednostavnija numerička metoda za rješavanje sistema diferencijalnih jednačina jeste eksplicitna Eulerova metoda.[2, 4] Polazeći od opšteg oblika sistema:

$$\frac{d\mathbf{T}}{dt} = \mathbf{f}(\mathbf{T}, t),$$

Eulerova metoda aproksimira izvod kao konačnu razliku:

$$\frac{d\mathbf{T}}{dt} \approx \frac{\mathbf{T}_{n+1} - \mathbf{T}_n}{\Delta t}.$$

Odavde slijedi iterativna formula:

$$\mathbf{T}_{n+1} = \mathbf{T}_n + \Delta t\, \mathbf{f}(\mathbf{T}_n, t_n).$$

Za posmatrani sistem toplotne razmjene, Eulerova metoda daje:

$$T_{1,n+1} = T_{1,n} - \Delta t \, \frac{k}{C_1}(T_{1,n} - T_{2,n}),$$

$$T_{2,n+1} = T_{2,n} + \Delta t \, \frac{k}{C_2}(T_{1,n} - T_{2,n}).$$

Iako je Eulerova metoda jednostavna za implementaciju i intuitivna, ona ima ograničenu tačnost i stabilnost. Greška metode je reda $O(\Delta t)$, što znači da se tačnost značajno poboljšava samo smanjenjem vremenskog koraka, uz povećanje računarskog vremena.

6.3 Heunova metoda (poboljšana Eulerova metoda)

Kako bi se povećala tačnost u odnosu na klasičnu Eulerovu metodu, često se koristi poboljšana Eulerova metoda, poznata i kao Heunova metoda. Ova metoda koristi predikciju i korekciju kako bi se uzela u obzir promjena izvoda unutar vremenskog koraka.

Algoritam metode se sastoji od dva koraka:

1. Predikcija:

$$\mathbf{T}^* = \mathbf{T}_n + \Delta t \, \mathbf{f}(\mathbf{T}_n, t_n),$$

2. Korekcija:

$$\mathbf{T}_{n+1} = \mathbf{T}_n + \frac{\Delta t}{2} \left[\mathbf{f}(\mathbf{T}_n, t_n) + \mathbf{f}(\mathbf{T}^*, t_{n+1}) \right].$$

Heunova metoda ima grešku reda $O(\Delta t^2)$, što je čini znatno preciznijom u odnosu na osnovnu Eulerovu metodu, uz relativno malo povećanje računarske složenosti.

6.4 Runge–Kutta metoda četvrtog reda

Jedna od najčešće korištenih metoda u numeričkim simulacijama jeste Runge–Kutta metoda četvrtog reda (RK4).

Za sistem diferencijalnih jednačina, RK4 metoda se definiše kroz četiri procjene izvoda:

$$\mathbf{k}_1 = \mathbf{f}(\mathbf{T}_n, t_n),$$

$$\mathbf{k}_2 = \mathbf{f}\left(\mathbf{T}_n + \frac{\Delta t}{2}\mathbf{k}_1, t_n + \frac{\Delta t}{2}\right),$$

$$\mathbf{k}_3 = \mathbf{f}\left(\mathbf{T}_n + \frac{\Delta t}{2}\mathbf{k}_2, t_n + \frac{\Delta t}{2}\right),$$

$$\mathbf{k}_4 = \mathbf{f}\left(\mathbf{T}_n + \Delta t\,\mathbf{k}_3, t_n + \Delta t\right).$$

Konačna vrijednost u narednom koraku računa se kao:

$$\mathbf{T}_{n+1} = \mathbf{T}_n + \frac{\Delta t}{6}(\mathbf{k}_1 + 2\mathbf{k}_2 + 2\mathbf{k}_3 + \mathbf{k}_4).$$

RK4 metoda ima lokalnu grešku reda $O(\Delta t^5)$ i globalnu grešku reda $O(\Delta t^4)$, što je čini veoma preciznom čak i za relativno velike vremenske korake.

6.5 Stabilnost i izbor vremenskog koraka

Stabilnost numeričke metode predstavlja ključni aspekt simulacije. Za posmatrani sistem, prevelik vremenski korak može dovesti do numeričkih oscilacija ili divergencije rješenja, naročito kod Eulerove metode. Stoga je neophodno pažljivo odabrati Δt u zavisnosti od vremenske konstante sistema:

$$\tau = \frac{C_1 C_2}{k(C_1 + C_2)}.$$

U praksi se zahtijeva da $\Delta t \ll \tau$, kako bi se osigurala stabilnost i tačnost rezultata.[2] U ovom radu različite vrijednosti vremenskog koraka bit će analizirane i upoređene kroz numeričke eksperimente.

7 Implementacija simulacije

U ovom poglavlju prikazana je detaljna implementacija simulacije procesa toplotne razmjene između dva tijela. Implementacija je realizovana u programskom jeziku Python.
Izbor numeričke metode direktno utiče na strukturu implementacije. Kako bi se omogućilo jasno poređenje metoda i fleksibilnost simulacije, implementacija će biti organizovana modularno, sa posebnim funkcijama za:

- definiciju sistema diferencijalnih jednačina,
- svaku numeričku metodu (Euler, Heun, RK4),
- upravljanje simulacionim parametrima,

- prikupljanje i vizualizaciju rezultata.

U nastavku je predstavljena struktura programskog rješenja, uz objašnjenje funkcionalnosti pojedinih modula.

7.1 Modul `model.py`: fizički model i analitičko rješenje

U ovome dijelu implementiran je fizički model zatvorenog sistema dva tijela koja razmjenjuju toplotu. Svako tijelo se opisuje masom m, specifičnim toplotnim kapacitetom c i temperaturom $T(t)$. Model se zasniva na prvom zakonu termodinamike i pretpostavci da je tok toplote proporcionalan razlici temperatura između tijela.

Model je:

$$\frac{dT_1}{dt} = -\frac{K}{m_1 c_1}(T_1 - T_2), \qquad \frac{dT_2}{dt} = \frac{K}{m_2 c_2}(T_1 - T_2).$$

Prikazani isječak koda predstavlja ključnu funkcionalnost fizičkog modela, odnosno izračun vremenskih izvoda temperatura na osnovu trenutnog stanja sistema. Funkcija `derivatives` direktno implementira sistem diferencijalnih jednačina izveden u prethodnom poglavlju, pri čemu se izvodi $\frac{dT_1}{dt}$ i $\frac{dT_2}{dt}$ računaju kao funkcije trenutnih temperatura tijela i njihovih toplotnih masa. Na ovaj način fizički model je u potpunosti nezavisan od izbora numeričke metode.

```python
@dataclass
class TwoBodyThermalSystem:
    m1: float; c1: float
    m2: float; c2: float
    K: float

    def derivatives(self, T1: float, T2: float) -> Tuple[float, float]:
        C1 = self.m1 * self.c1
        C2 = self.m2 * self.c2
        dT1_dt = -(self.K / C1) * (T1 - T2)
        dT2_dt = +(self.K / C2) * (T1 - T2)
        return dT1_dt, dT2_dt
```

Listing 1: Definicija izvoda temperatura

Dodatno je implementirano i analitičko rješenje (za zatvoren sistem), što omogućava validaciju numeričkih metoda i računanje greške.
Kompletna implementacija modula, uključujući definiciju ravnotežne temperature i analitičkog rješenja sistema, data je u Dodatku A.

7.2 Modul `numerical_methods.py`: Euler, Heun i RK4

Numeričko rješavanje sistema diferencijalnih jednačina realizovano je pomoću tri eksplicitne metode: Eulerove metode, Heunove metode i Runge–Kutta metode četvrtog reda.

7.2.1 Eulerova metoda (metoda prvog reda)

Implementacija Eulerove metode realizovana je kroz funkciju koja izvršava jedan vremenski korak numeričke integracije. Funkcija kao ulaz prima instancu fizičkog modela, trenutno stanje sistema u obliku para (T_1, T_2) i vrijednost vremenskog koraka Δt.
U svakom koraku simulacije, metoda poziva funkciju `derivatives` iz modula `model.py` kako bi se izračunali izvodi temperatura u trenutnom stanju. Dobijeni izvodi zatim se koriste za direktno ažuriranje temperatura oba tijela.

```python
from __future__ import annotations
from typing import Tuple
from model import TwoBodyThermalSystem

State = Tuple[float, float] # (T1, T2)

def euler_step(system: TwoBodyThermalSystem, state: State, dt: float) -> State:
    T1, T2 = state
    dT1, dT2 = system.derivatives(T1, T2)
    return (T1 + dt * dT1, T2 + dt * dT2)
```

Listing 2: Eulerov metoda

Ovaj isječak koda ilustruje način na koji se fizički model koristi u okviru numeričke metode. Ostale metode (Heun i Runge–Kutta četvrtog reda) implementirane su analogno i date su u Dodatku A.

7.2.2 Heunova metoda (poboljšani Euler, metoda drugog reda)

Heunova metoda implementirana je tako da u svakom vremenskom koraku koristi dva proračuna izvoda temperatura. Funkcija prima trenutno stanje sistema i vremenski korak Δt, te vraća novo stanje sistema. U prvom koraku izračunavaju se izvodi temperatura u trenutnom stanju pomoću funkcije `derivatives`, na osnovu kojih se dobija privremeno stanje sistema. Zatim se u tom privremenom stanju ponovo računaju izvodi temperatura. Konačno stanje u narednom vremenskom koraku dobija se korištenjem prosječne vrijednosti izvoda na početku i na kraju vremenskog intervala. Na ovaj način postiže se bolja tačnost u odnosu na osnovnu Eulerovu metodu, uz blago povećanje računarskog vremena.

7.2.3 Runge–Kutta metoda četvrtog reda (RK4)

Kao i kod ostalih metoda, i kod RK4 metode, za računanje izvoda koristi se ista funkcija fizičkog modela. Ova metoda koristi četiri procjene nagiba k_1, k_2, k_3, k_4 unutar jednog vremenskog koraka: na početku intervala, u dvije međutačke i na kraju intervala. Na osnovu tih proračuna dobija se novo stanje sistema u narednom vremenskom trenutku.

7.3 Modul `simulation.py`: simulacioni algoritam i računanje greške

Modul `simulation.py` predstavlja centralni dio simulacije, jer povezuje fizički model sistema i izabranu numeričku metodu u jedinstven algoritam. Njegova uloga je da izvrši vremensku diskretizaciju problema i iterativno izračuna razvoj sistema od početnog do krajnjeg vremena simulacije, pri čemu se numerička metoda bira dinamički radi poređenja različitih metoda.

Tokom simulacije pohranjuju se vremenske tačke i vrijednosti temperatura oba tijela, dok dodatne funkcije omogućavaju računanje greške u odnosu na analitičko rješenje i mjerenje vremena izvršavanja, čime se vrši kvantitativna analiza tačnosti i efikasnosti numeričkih metoda.

Kompletna implementacija modula `simulation.py` data je u Dodatku A.

7.4 Modul `visualization.py`: grafički prikaz rezultata

Vizualizacija predstavlja važan dio analize simulacije, jer omogućava intuitivan uvid u vremenski razvoj temperatura i proces uspostavljanja termičke ravnoteže.
Modul `visualization.py` omogućava grafički prikaz sljedećih veličina:

- vremenskog razvoja temperatura oba tijela (promjene temperature), $T_1(t)$ i $T_2(t)$,
- razlike temperatura $\Delta T(t) = T_1(t) - T_2(t)$ u vremenu,
- vremena potrebnog da sistem dostigne termičku ravnotežu za različite scenarije

Funkcija za prikaz temperatura iscrtava $T_1(t)$ i $T_2(t)$ na istom grafiku, čime je omogućeno direktno poređenje dinamike oba tijela. Radi lakšeg razlikovanja numeričkih metoda, koriste se različiti stilovi linija i boje, dok je temperatura prvog tijela prikazana punom linijom, a temperatura drugog tijela isprekidanom linijom.
Grafik razlike temperatura $\Delta T(t)$ posebno je pogodan za analizu dinamike procesa, jer jasno ilustruje opadanje temperaturne razlike i postepeno uspostavljanje termičke ravnoteže. Horizontalna referentna linija na $\Delta T = 0$ uvedena je kao pokazatelj ravnotežnog stanja.
Pored vremenskih grafova, implementirana je i funkcija za prikaz vremena u obliku row chart dijagrama potrebnog da sistem dostigne termičku ravnotežu u različitim scenarijima. Ovaj prikaz omogućava analizu uticaja fizičkih parametara, kao što su toplotni kapaciteti tijela i koeficijent termičke veze, na brzinu procesa toplotne razmjene.

Kao ilustracija osnovnog principa grafičkog prikaza rezultata, u nastavku je dat skraćeni isječak koda za iscrtavanje temperatura oba tijela u vremenu:

```
plt.figure()
plt.plot(times, T1, label="$T_1(t)$")
plt.plot(times, T2, linestyle="--", label="$T_2(t)$")
plt.xlabel("Vrijeme [s]")
plt.ylabel("Temperatura [$^\circ$C]")
plt.legend()
plt.grid(True)
```

Listing 3: Primjer grafičkog prikaza temperatura

7.5 Modul `scenarios.py`: definisanje fizičkih scenarija

Radi ispitivanja ponašanja sistema u različitim fizičkim uslovima, definisan je skup simulacionih scenarija koji se razlikuju po masama tijela, specifičnim toplotnim kapacitetima, početnim temperaturama i koeficijentu termičke veze.

U inženjerskim modelima termičkih sistema često se koristi pojam ***toplotne mase*** kako bi se naglasila uloga ukupnog toplotnog kapaciteta u dinamici sistema.[5] Toplotna masa opisuje koliko tijelo „usporava“ promjenu temperature pri razmjeni toplote i predstavlja intuitivnu mjeru termičke inercije tijela.

U ovom radu, toplotna masa tijela je definisana ukupnim toplotnim kapacitetom $C = m \cdot c$, gdje je m masa tijela, a c njegov specifični toplotni kapacitet.

Vrijeme simulacije t_{end} u svakom scenariju odabrano je na osnovu karakterističnog vremena sistema, definisanog vremenskom konstantom $\tau = \frac{C_1 C_2}{K(C_1+C_2)}$, pri čemu je uzeto $t_{\text{end}} \gtrsim 5\tau$ kako bi se osiguralo približavanje termičkoj ravnoteži.

Scenario A: Simetrične toplotne mase

U scenariju A razmatra se slučaj približno jednakih toplotnih masa oba tijela. Ulazni parametri scenarija su:

- $m_1 = 2.0\,\text{kg}$, $c_1 = 500\,\text{J/(kg K)}$,
- $m_2 = 1.0\,\text{kg}$, $c_2 = 1000\,\text{J/(kg K)}$,
- početne temperature $T_1 = 80°\text{C}$ i $T_2 = 20°\text{C}$,
- koeficijent termičke veze $K = 50\,\text{W/K}$.

Iz ovih vrijednosti slijedi da su toplotne mase tijela jednake:

$$C_1 = m_1 c_1 = 1000\,\text{J/K}, \qquad C_2 = m_2 c_2 = 1000\,\text{J/K}.$$

Navedeni fizički parametri direktno se koriste u numeričkoj simulaciji kao ulazni podaci za matematički model. U nastavku je dat primjer definicije Scenarija A u programskom kodu.

```
        {
            "name": "Scenario A: Simetricni kapaciteti (C1=C2)",
            "m1": 2.0, "c1": 500.0,
            "m2": 1.0, "c2": 1000.0,
            "T1": 80.0, "T2": 20.0,
            "K": 50.0,
            "t_end": 60.0,
            "dt": 0.5
        },
```

Listing 4: Primjer definicije scenarija A

Kodovi za ostale scenarije dati su u Dodatku A.

Scenario B: Velika razlika toplotnih masa

Scenario B ispituje uticaj velike razlike u toplotnim masama tijela na proces toplotne razmjene. Razmatrana su dva podslučaja sa istim fizičkim parametrima, ali različitim rasporedom početnih temperatura. Ulazni parametri zajednički za oba podslučaja su:

- $m_1 = 2.5\,\mathrm{kg}$, $c_1 = 500\,\mathrm{J/(kg\,K)}$,
- $m_2 = 2.0\,\mathrm{kg}$, $c_2 = 500\,\mathrm{J/(kg\,K)}$,
- koeficijent termičke veze $K = 50\,\mathrm{W/K}$.

Toplotne mase tijela su:

$$C_1 = m_1 c_1 = 1250\,\mathrm{J/K}, \qquad C_2 = m_2 c_2 = 1000\,\mathrm{J/K},$$

što predstavlja razliku od 25% u toplotnoj masi.
Razmatranjem oba rasporeda početnih temperatura unutar istog scenarija omogućeno je poređenje ponašanja sistema pri istoj razlici u toplotnim masama, ali uz različite uloge toplijeg i hladnijeg tijela.
U prvom slučaju (podscenario B1) tijelo sa većom toplotnom masom ima višu početnu temperaturu:

$$T_1 = 80^\circ\mathrm{C}, \qquad T_2 = 20^\circ\mathrm{C}.$$

U drugom slučaju (podscenario B2) razmatra se obrnuta situacija, u kojoj tijelo sa većom toplotnom masom ima nižu početnu temperaturu:

$$T_{1,0} = 20°\mathrm{C}, \qquad T_{2,0} = 80°\mathrm{C}.$$

Scenario C: Slaba termička veza (mali K)

Scenario C definiše slučaj slabe termičke veze između tijela, što je modelirano malom vrijednošću koeficijenta K. Ulazni parametri scenarija su:

- $m_1 = m_2 = 1.0\,\mathrm{kg}$,
- $c_1 = c_2 = 500\,\mathrm{J/(kg\,K)}$,
- početne temperature $T_1 = 80°\mathrm{C}$ i $T_2 = 20°\mathrm{C}$,
- koeficijent termičke veze $K = 5\,\mathrm{W/K}$.

Toplotne mase tijela su jednake i iznose

$$C_1 = C_2 = 500\,\mathrm{J/K}.$$

Scenario D: Jednake toplotne mase i velika početna razlika temperatura

Scenario D definiše slučaj u kojem oba tijela imaju jednake toplotne mase, ali se značajno razlikuju po početnim temperaturama. Na ovaj način izoluje se uticaj početnih uslova na dinamiku sistema, bez uticaja razlike u toplotnim masama.

Ulazni parametri scenarija su:

- $m_1 = m_2 = 1.0\,\mathrm{kg}$,
- $c_1 = c_2 = 1000\,\mathrm{J/(kg\,K)}$,
- početne temperature $T_1 = 150°\mathrm{C}$ i $T_2 = 0°\mathrm{C}$,
- koeficijent termičke veze $K = 50\,\mathrm{W/K}$.

Toplotne mase tijela su jednake i iznose

$$C_1 = C_2 = 1000\,\mathrm{J/K}.$$

7.6 Modul `analysis.py`: analiza greške i vremena izvršavanja

Modul `analysis.py` sadrži pomoćne funkcije koje služe za poređenje numeričkih metoda. Funkcija `error_sweep` računa grešku u odnosu na analitičko rješenje za više vrijednosti vremenskog koraka Δt. Rezultati se organizuju po metodama, što omogućava jednostavno poređenje tačnosti metoda pri različitim koracima.

Funkcija `runtime_sweep` mjeri prosječno vrijeme izvršavanja simulacije za svaku metodu (uz više ponavljanja), kako bi se uporedila njihova računarska efikasnost.

Kompletna implementacija modula data je u DodatkuA.

7.7 Glavni program `main.py`

Radi jasnijeg prikaza logičkog toka izvođenja simulacije i međusobne povezanosti programskih modula, na slici je prikazan dijagram toka glavnog programa `main.py`.

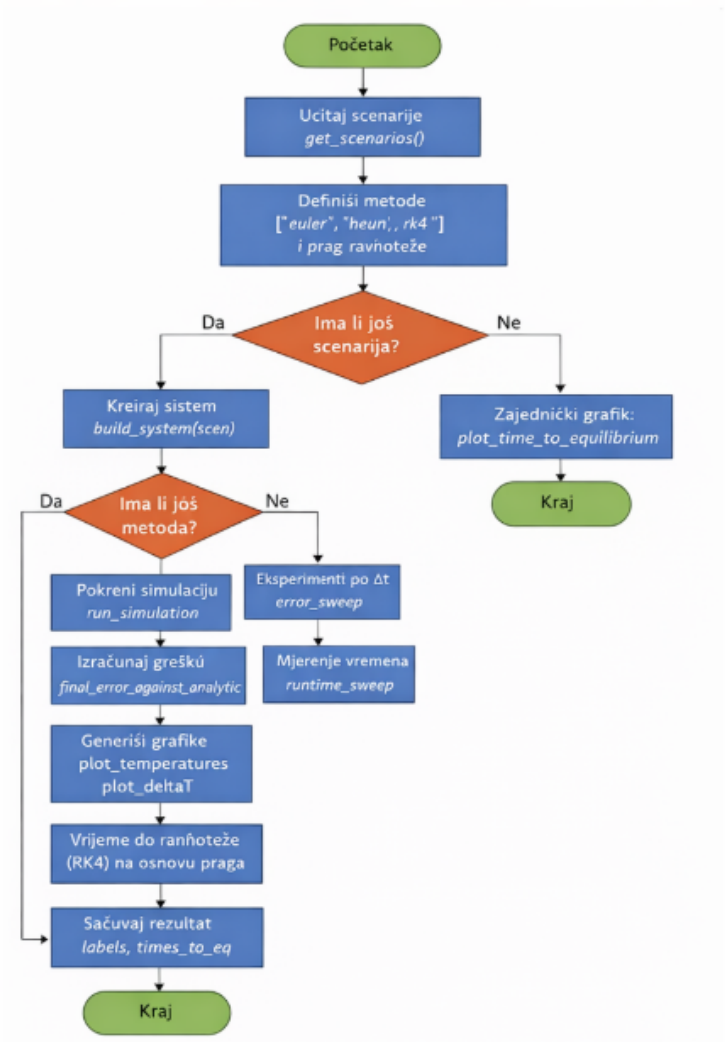

Slika 4: Dijagram toka glavnog programa `main.py`.

Glavni program (`main.py`) povezuje sve prethodno implementirane module i upravlja izvođenjem simulacija. Program najprije učitava listu scenarija iz modula `scenarios.py` i definiše skup numeričkih metoda koje se koriste u poređenju (Euler, Heun i RK4).
Za svaki scenarij kreira se instanca fizičkog sistema, nakon čega se simulacija pokreće za svaku numeričku metodu. Tokom izvođenja, program prikuplja vremenske nizove temperatura, računa grešku u odnosu na analitičko rješenje (kada je dostupno), te generiše odgovarajuće grafičke prikaze.
Ovime je završena implementacija, te će u nastavku biti prikazani rezultati, analiza istih, kao i grafički prikazi.

8 Analiza rezultata

U ovom poglavlju analizirani su rezultati numeričke simulacije prenosa toplote između dva tijela. Poseban naglasak stavljen je na fizičku interpretaciju dobijenih rješenja, kao i na poređenje različitih numeričkih metoda u pogledu tačnosti i računske efikasnosti.

8.1 Scenario A: Simetrične toplotne mase ($C_1 = C_2$)

Scenario A predstavlja osnovni referentni slučaj u kojem oba tijela imaju jednake toplotne mase, odnosno jednake ukupne toplotne kapacitete. Zbog ove simetrije očekuje se identično dinamičko ponašanje sistema pri razmjeni toplote, uz ravnomjerno približavanje ravnotežnoj temperaturi.
Analitičko rješenje za ovaj slučaj daje ravnotežnu temperaturu

$$T_{\text{eq}} = 50\ ^\circ\text{C},$$

što je u potpunosti potvrđeno i numeričkim simulacijama. Koeficijent razmjene toplote iznosi $\lambda = 0.1\ \text{s}^{-1}$, što odgovara relativno brzom izjednačavanju temperatura tijela.

Eulerova metoda

Na slici 5 prikazan je vremenski razvoj temperatura oba tijela dobijen Eulerovom metodom. Uočava se monotono približavanje temperatura ravnotežnoj vrijednosti, pri čemu toplije tijelo postepeno predaje toplotu hladnijem tijelu.

Zbog jednakih toplotnih masa tijela ($C_1 = C_2$), temperaturne krive su simetrične u odnosu na ravnotežnu temperaturu. Oba tijela mijenjaju temperaturu jednakom brzinom, ali u suprotnim smjerovima, što rezultira gotovo zrcalnim oblikom krivih $T_1(t)$ i $T_2(t)$ oko vrijednosti T_{eq}.

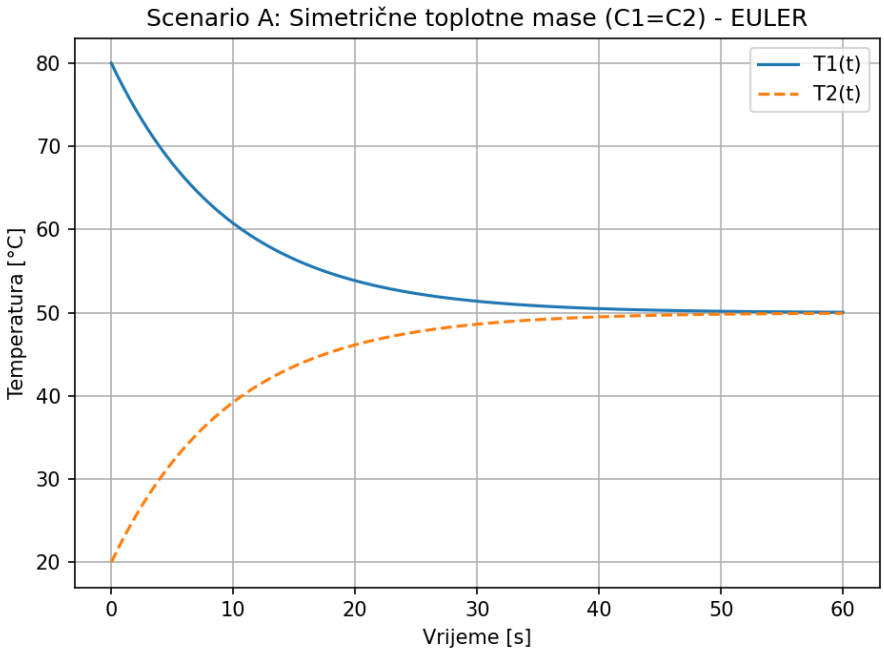

Slika 5: Vremenski tok temperatura $T_1(t)$ i $T_2(t)$ za Scenario A dobijen Eulerovom metodom

Slika 6 ilustruje vremenski tok razlike temperatura $\Delta T(t) = T_1(t) - T_2(t)$ tokom procesa toplotne razmjene. Kriva pokazuje eksponencijalni pad razlike temperatura, što je u potpunoj saglasnosti sa teorijskim modelom toplotne razmjene. Ova razlika asimptotski se približava nuli, čime se označava dostizanje termičke ravnoteže sistema.

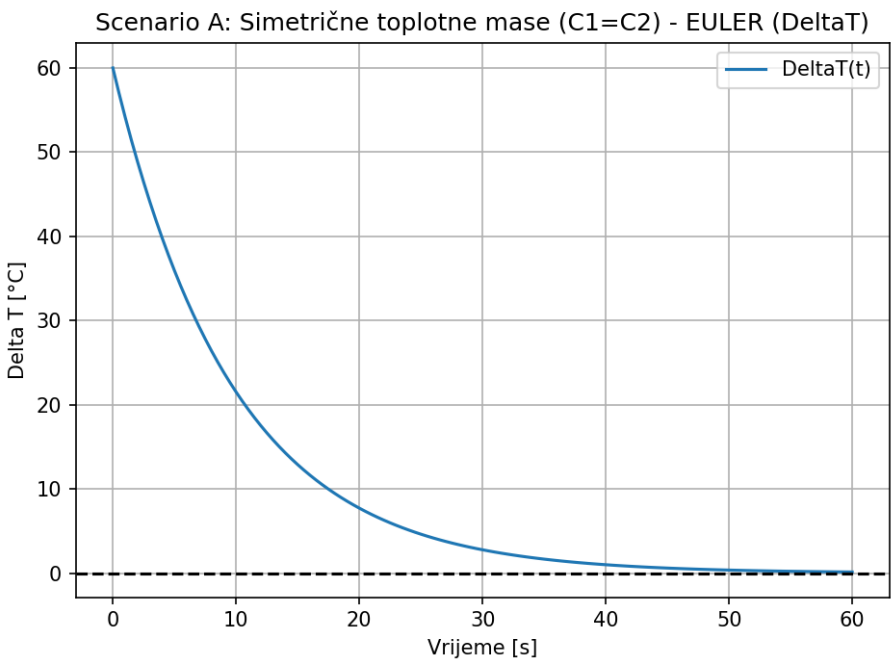

Slika 6: Vremenski tok razlike temperatura $\Delta T(t)$ za Scenario A dobijen Eulerovom metodom

Numerički rezultati pokazuju da je greška Eulerove metode u konačnom vremenu simulacije reda veličine 10^{-2} °C za vremenski korak $\Delta t = 0.5$ s, što je očekivano za metodu prvog reda.

Runge–Kutta metoda četvrtog reda

Runge–Kutta metoda četvrtog reda predstavlja numeričku metodu višeg reda tačnosti i često se koristi kao referentna metoda za poređenje sa jednostavnijim algoritmima. Zbog svoje visoke preciznosti, očekuje se vrlo dobro slaganje numeričkog rješenja sa analitičkim rješenjem problema.

Radi poređenja, na slici 7 prikazan je vremenski tok razlike temperatura dobijen Runge–Kutta metodom četvrtog reda (RK4). Uočava se gotovo savršeno poklapanje numeričkog rješenja sa analitičkim eksponencijalnim padom razlike temperatura.

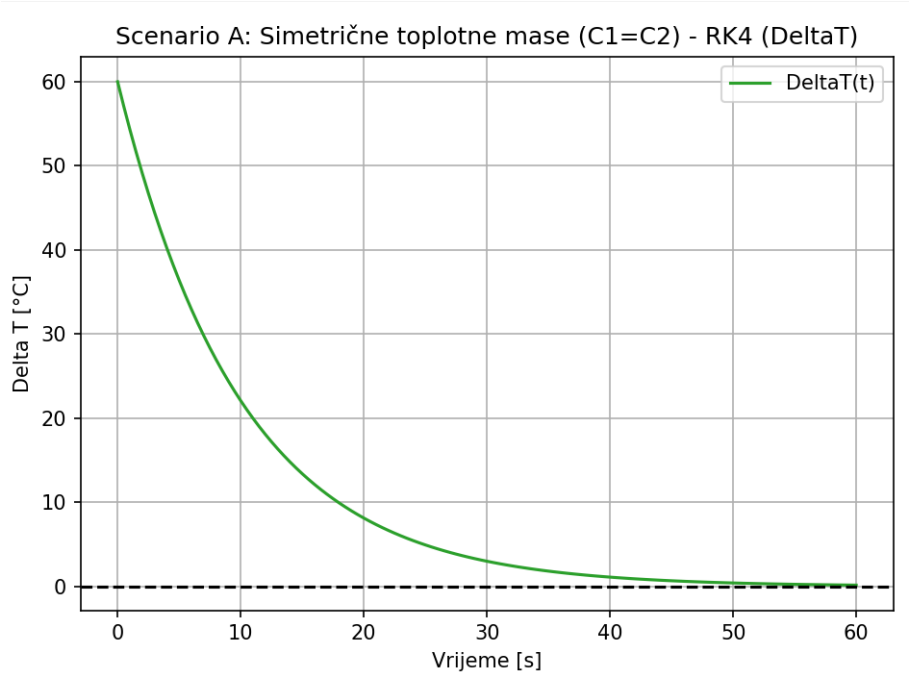

Slika 7: Vremenski tok razlike temperatura $\Delta T(t)$ za Scenario A dobijen RK4 metodom

Greška RK4 metode u konačnom vremenu simulacije praktično je zanemarljiva i u okviru numeričke preciznosti iznosi nulu za sve razmatrane vrijednosti vremenskog koraka. Ovaj rezultat potvrđuje visoku tačnost RK4 metode, ali i njenu veću računsku složenost u poređenju sa Eulerovom i Heunovom metodom.

Na osnovu prikazanih rezultata može se zaključiti da Scenario A jasno ilustruje razliku u tačnosti između metoda prvog i višeg reda, pri čemu RK4 metoda gotovo u potpunosti eliminiše numeričku grešku prisutnu kod Eulerove metode.

8.2 Scenario B: Velika razlika toplotne mase ($C_1 \gg C_2$)

Scenario B ispituje uticaj razlike u toplotnim masama tijela na dinamiku toplotne razmjene. U oba podscenarija toplotna masa prvog tijela veća je od toplotne mase drugog tijela, dok se razlikuje raspored početnih temperatura.
Vrijednost koeficijenta razmjene toplote iznosi $\lambda = 0.09\ \mathrm{s}^{-1}$, što ukazuje na zanemarljivo sporiju dinamiku izjednačavanja u poređenju sa Scenariom A.
Numerička simulacija za oba slučaja izvedena je Heunovom metodom, te su grafici prikazani u nastavku.

Scenario B1 - toplije tijelo ima veću toplotnu masu

Analitička ravnotežna temperatura sistema iznosi

$$T_{\text{eq}} = 53.3333\ ^\circ\text{C},$$

što se poklapa sa rezultatima simulacije.

Na slici 8 prikazan je vremenski razvoj temperatura za podscenario B1, u kojem tijelo sa većom toplotnom masom (T_1) ima višu početnu temperaturu. Uočava se da temperatura tijela T_1 opada sporije u odnosu na porast temperature tijela T_2, što je direktna posljedica veće toplotne mase prvog tijela.

Veća toplotna masa znači da je za istu količinu razmijenjene toplote potrebna manja promjena temperature, zbog čega tijelo T_1 pokazuje izraženiju termičku inerciju. Istovremeno, tijelo sa manjom toplotnom masom brže reaguje na prenos toplote i njegova temperatura se brže približava ravnotežnoj vrijednosti.

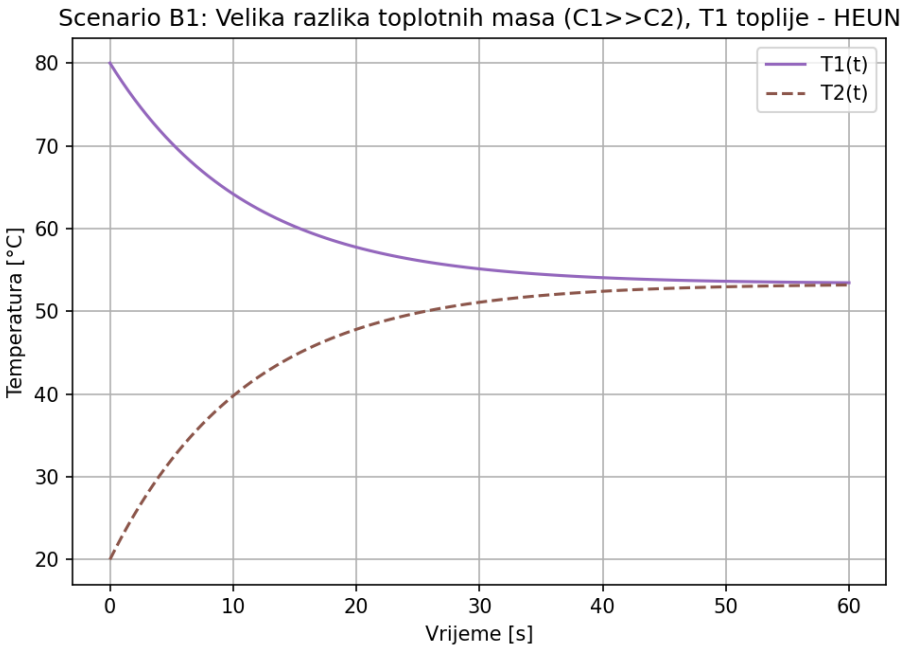

Slika 8: Vremenski tok temperatura $T_1(t)$ i $T_2(t)$ za Scenario B1 dobijen Heunovom metodom

Scenario B2 – hladnije tijelo ima veću toplotnu masu

Analitička ravnotežna temperatura sistema iznosi

$$T_{\text{eq}} = 46.6667\ ^\circ\text{C}.$$

Na slici 9 prikazan je podscenario B2, u kojem tijelo sa većom toplotnom masom (T_1) ima nižu početnu temperaturu. I u ovom slučaju uočava se asimetričan tok temperatura, ali sa obrnutim ulogama u odnosu na Scenario B1.
Temperatura tijela sa većom toplotnom masom raste sporije, dok tijelo sa manjom toplotnom masom brže gubi toplotu.

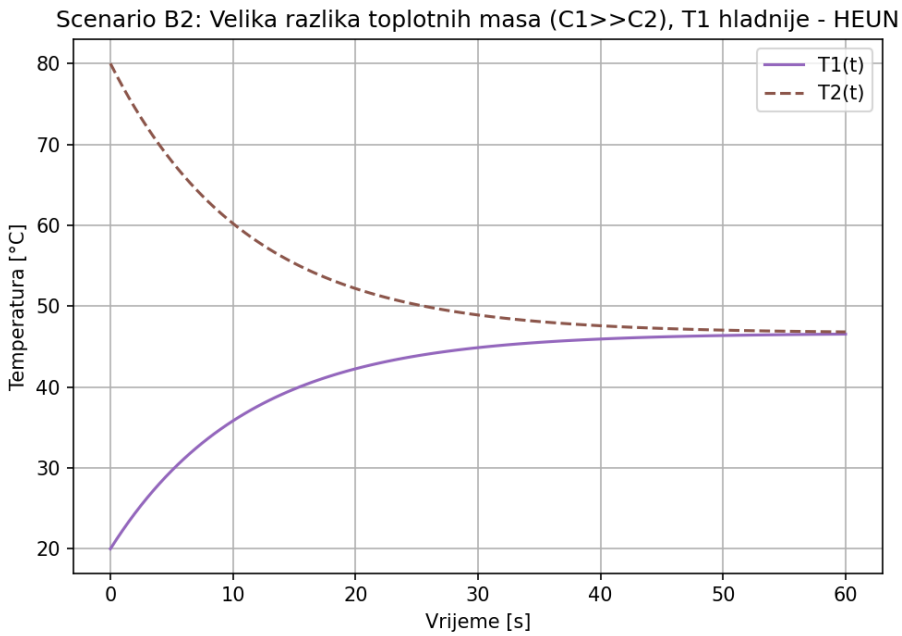

Slika 9: Vremenski tok temperatura $T_1(t)$ i $T_2(t)$ za Scenario B dobijen Heunovom metodom

Rezultati Scenarija B pokazuju da neravnomjerna raspodjela toplotnih masa dovodi do asimetrične razmjene toplote i pomjeranja ravnotežne temperature ka tijelu sa većom toplotnom masom. U oba podscenarija tijelo sa većom toplotnom masom pokazuje sporiju promjenu temperature, bez obzira na to da li je inicijalno toplije ili hladnije.

Razlika temperatura

Na slici 10 prikazan je vremenski tok razlike temperatura $\Delta T(t) = T_1(t) - T_2(t)$ za Scenario B2. Za razliku od Scenarija A, gdje je početna razlika temperatura pozitivna, u ovom slučaju vrijedi $\Delta T(0) < 0$, budući da je tijelo sa većom toplotnom masom inicijalno hladnije od drugog tijela.

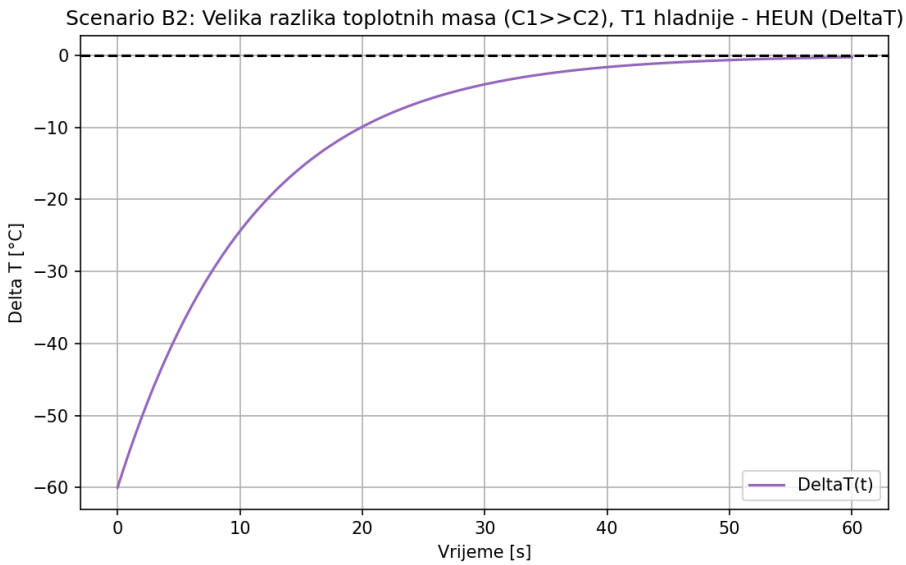

Slika 10: Vremenski tok razlike temperatura $\Delta T(t)$ za Scenario B2

Negativna početna vrijednost razlike temperatura dovodi do „obrnuto orijentisane“ krive u odnosu na Scenario A, pri čemu se $\Delta T(t)$ monotono povećava ka nuli. Ovaj oblik krive ne označava drugačiju fiziku procesa, već isključivo promjenu smjera prenosa toplote.
Bez obzira na znak početne razlike temperatura, dinamika procesa ostaje eksponencijalna i određena istim koeficijentom razmjene toplote λ.

8.3 Scenario C: Slaba termička veza (mali K)

Prikazan je vremenski razvoj temperatura oba tijela za Scenario C, u kojem je termička veza između tijela slaba zbog male vrijednosti koeficijenta prenosa toplote K. Ravnotežna temperatura sistema iznosi

$$T_{\text{eq}} = 50\ ^\circ\text{C},$$

što odgovara slučaju jednakih toplotnih masa tijela i u potpunosti je u skladu sa analitičkim rješenjem.

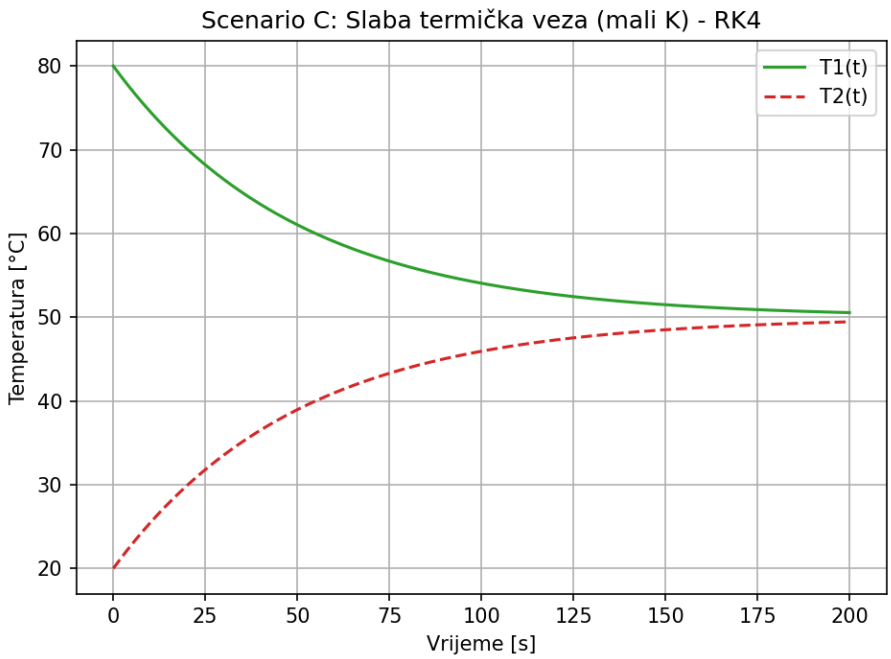

Slika 11: Vremenski tok temperatura za Scenario C dobijen RK4 metodom

U poređenju sa Scenarijem A, uočava se kvalitativno identično ponašanje sistema: toplije tijelo postepeno predaje toplotu hladnijem tijelu, a temperaturne krive se monotono približavaju ravnotežnoj vrijednosti. Međutim, proces razmjene toplote je znatno sporiji, što je direktna posljedica manje vrijednosti koeficijenta termičke veze.

Vrijednost koeficijenta razmjene toplote u ovom scenariju iznosi $\lambda = 0.02\ \mathrm{s}^{-1}$, što je višestruko manje u odnosu na Scenario A. Zbog toga je potrebno znatno duže vrijeme da se sistem približi termičkoj ravnoteži, što se jasno vidi iz produženog vremenskog opsega simulacije, koji sada traje 200 sekundi, u odnosu na prethodni od 60 sekundi.

8.4 Scenario D: Jednake toplotne mase, velika početna razlika temperatura

Scenario D razmatra slučaj u kojem su toplotne mase tijela jednake ($C_1 = C_2$), ali je početna razlika temperatura izrazito velika. Na osnovu očuvanja energije, ravnotežna temperatura zatvorenog sistema iznosi

$$T_{\mathrm{eq}} = 75.0\ ^{\circ}\mathrm{C}.$$

Koeficijent razmjene toplote u ovom scenariju iznosi $\lambda = 0.1\ \mathrm{s}^{-1}$, pa je brzina izjednačavanja temperatura uporediva sa Scenarijem A, dok se razlikuje intenzitet početnog prenosa toplote zbog većeg temperaturnog gradijenta.

Na slici 12 prikazan je vremenski razvoj temperatura dobijen RK4 metodom.

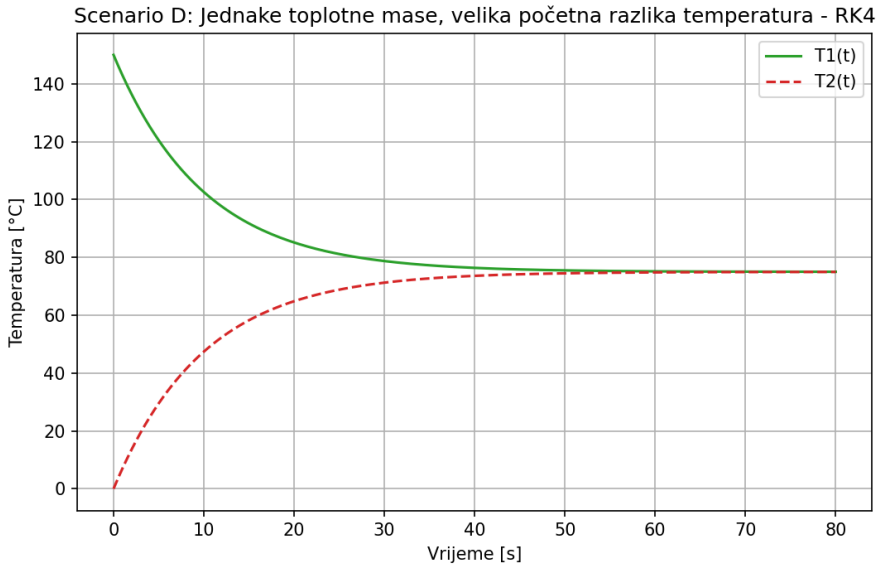

Slika 12: Vremenski tok temperatura za Scenario D dobijen RK4 metodom

Uočava se monotono približavanje ravnotežnoj vrijednosti: temperatura toplijeg tijela $T_1(t)$ opada, dok temperatura hladnijeg tijela $T_2(t)$ raste. Zbog jednakih toplotnih masa, krive su približno simetrične u odnosu na T_{eq}, odnosno oba tijela mijenjaju temperaturu sličnom brzinom, ali u suprotnim smjerovima.

Velika početna razlika temperatura rezultira strmijim nagibom krivih u početnoj fazi simulacije, što ukazuje na intenzivan prenos toplote na početku procesa. Kako se razlika temperatura smanjuje, prenos toplote se postepeno usporava, pa se približavanje ravnoteži odvija sve sporije, u skladu sa eksponencijalnim karakterom modela.

Primjena RK4 metode je posebno pogodna u ovom scenariju jer obezbjeđuje visoku tačnost i stabilnost pri velikim početnim promjenama temperatura, što omogućava pouzdano numeričko praćenje faze do dostizanja termičke ravnoteže.

8.5 Poređenje scenarija: vrijeme do termičke ravnoteže

U cilju kvantitativne analize dinamike procesa razmjene toplote, dodatno je određeno vrijeme potrebno da sistem praktično dostigne termičku ravnotežu. Kao kriterij ravnoteže usvojeno je da je apsolutna razlika temperatura manja od zadate granice,

$$|\Delta T(t)| = |T_1(t) - T_2(t)| < 1^\circ\mathrm{C}.$$

Vrijeme do ravnoteže određeno je numerički na osnovu simulacije RK4 metodom, kao prvi trenutak t u kojem je ispunjen navedeni uslov.

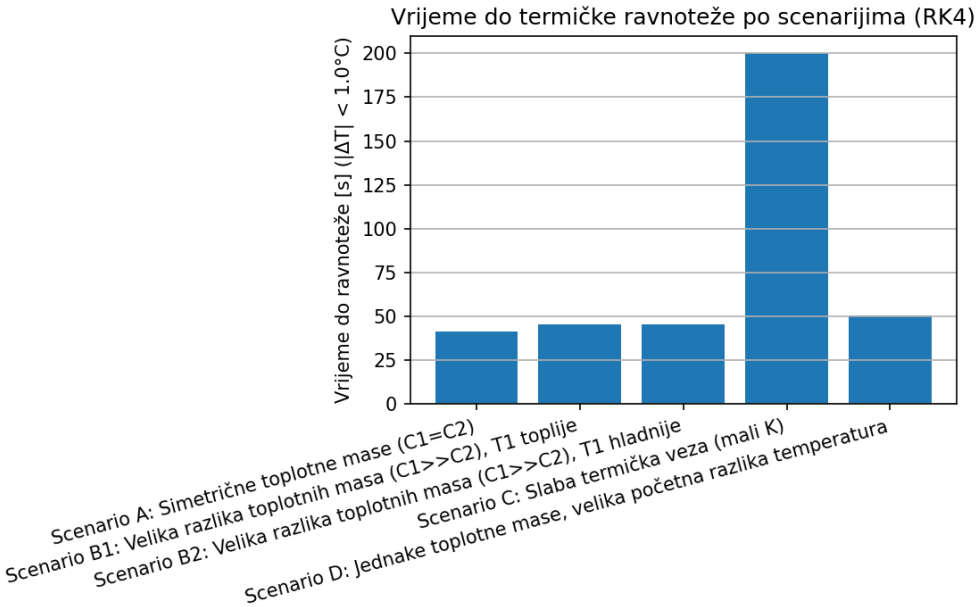

Slika 13: Vrijeme do termičke ravnoteže po scenarijima (RK4)

Na slici 13 prikazano je vrijeme do termičke ravnoteže za sve razmatrane scenarije. Uočava se da Scenario C (slaba termička veza, mali K) zahtijeva ubjedljivo najduže vrijeme za izjednačavanje temperatura. Ovakvo ponašanje je očekivano, budući da je intenzitet prenosa toplote proporcionalan koeficijentu K, pa njegova mala vrijednost značajno usporava dinamiku procesa.

Scenariji A, B1 i B2 dostižu termičku ravnotežu znatno brže i u sličnim vremenskim intervalima. Kod Scenarija B, iako postoji izražena razlika u toplotnim masama tijela, tijelo sa manjom toplotnom masom brzo reaguje na prenos toplote, što dovodi do relativno brzog smanjenja razlike temperatura i dostizanja ravnoteže.

Scenario D, koji se odlikuje jednakim toplotnim masama i velikom početnom razlikom

temperatura, pokazuje vrijeme do ravnoteže uporedivo sa Scenarijem A. Ovo potvrđuje da početna razlika temperatura utiče na intenzitet prenosa toplote u početnoj fazi procesa, ali ne i na ukupno vrijeme potrebno za dostizanje ravnoteže, koje je prvenstveno određeno parametrima sistema C_1, C_2 i K.

8.6 Poređenje grešaka

Tabela 1: Poređenje grešaka numeričkih metoda u konačnom vremenu ($\Delta t = 0.5$ s).

Scenario	**Metoda**	**Greška T_1 [°C]**
A	Euler	1.07×10^{-2}
A	Heun	1.93×10^{-4}
A	RK4	≈ 0
B	Euler	1.42×10^{-2}
B	Heun	2.27×10^{-4}
B	RK4	≈ 0
C	Euler	2.18×10^{-2}
C	Heun	1.49×10^{-4}
C	RK4	≈ 0
D	Euler	4.70×10^{-3}
D	Heun	8.7×10^{-5}
D	RK4	≈ 0

Iz tabele je vidljivo da Eulerova metoda pokazuje najveće greške u svim razmatranim scenarijima, što je očekivano obzirom na to da se radi o metodi prvog reda tačnosti. Najveće greške Eulerove metode javljaju se u Scenariju C. U ovom slučaju sporija dinamika sistema zahtijeva tačniju vremensku diskretizaciju, što čini jednostavne numeričke metode manje pogodnim bez dodatnog smanjenja vremenskog koraka.

Heunova metoda u svim scenarijima značajno smanjuje grešku u odnosu na Eulerovu metodu, zadržavajući pritom razumnu računarsku složenost.

Runge–Kutta metoda četvrtog reda daje praktično tačno rješenje u svim razmatranim slučajevima, čime se potvrđuje njena visoka tačnost u odnosu na promjene fizičkih parametara sistema.

9 Zaključak

U ovom seminarskom radu analiziran je proces prenosa toplote između dva tijela povezana idealizovanom termičkom vezom. Na osnovu zakona očuvanja energije izveden je matematički model koji opisuje vremenski razvoj temperatura dva tijela, pri čemu su jasno identifikovani ključni fizički parametri sistema: toplotne mase tijela ($C = mc$) i koeficijent termičke veze K.

Kroz definisane scenarije pokazano je da međusobni odnos ovih parametara ima presudan uticaj na ponašanje sistema. U slučaju simetričnih toplotnih masa, sistem pokazuje potpuno uravnoteženo ponašanje, pri čemu se temperature oba tijela približavaju ravnotežnoj vrijednosti istom brzinom. Kod velike razlike toplotnih masa, ravnotežna temperatura se pomjera prema tijelu sa većom toplotnom masom, koje se ponaša kao toplotni rezervoar i sporije mijenja svoju temperaturu. Time je jasno pokazano da toplotna masa ne utiče samo na dinamiku procesa, već i na sam položaj termičke ravnoteže.

Posebno je istaknut uticaj koeficijenta termičke veze K. U scenariju slabe termičke veze (mali K), iako je ravnotežna temperatura ista kao u simetričnom slučaju, vrijeme potrebno da sistem dostigne termičku ravnotežu znatno je duže. Ovo potvrđuje da vrijednost K direktno utiče na vremensku konstantu sistema i brzinu razmjene toplote, ali ne i na konačnu ravnotežnu temperaturu.

Zaključno, razvijeni model jasno ilustruje kako fizički parametri sistema (mase, toplotni kapaciteti i koeficijent termičke veze) određuju i ravnotežno stanje i dinamiku procesa prenosa toplote. Ovaj rad predstavlja dobru osnovu za dalja proširenja modela, kao što su uključivanje gubitaka toplote prema okolini, vremenski promjenjivih koeficijenata prenosa ili nelinearnih efekata karakterističnih za realne inženjerske sisteme.

Literatura

[1] F. P. Incropera, D. P. DeWitt, T. L. Bergman, A. S. Lavine, *Fundamentals of Heat and Mass Transfer*, John Wiley & Sons, 7th Edition, 2011.

[2] R. L. Burden, J. D. Faires, *Numerical Analysis*, Cengage Learning, 9th Edition, 2011.

[3] A. Šarić, M. Hadžiabdić, *Osnove termodinamike*, Prirodno-matematički fakultet, Univerzitet u Sarajevu.

[4] Z. Bjelanović, *Numeričke metode u inženjerstvu*, Elektrotehnički fakultet, Univerzitet u Sarajevu.

[5] Y. A. Çengel, A. J. Ghajar, *Heat and Mass Transfer: Fundamentals & Applications*, McGraw-Hill Education, 5th Edition, 2015.

[6] J. P. Holman, *Heat Transfer*, McGraw-Hill, 10th Edition, 2010.

[7] W. E. Boyce, R. C. DiPrima, *Elementary Differential Equations and Boundary Value Problems*, Wiley, 10th Edition, 2012.

[8] S. C. Chapra, R. P. Canale, *Numerical Methods for Engineers*, McGraw-Hill, 7th Edition, 2015.

A Dodatak: Kodovi

model.py

```python
from __future__ import annotations
from dataclasses import dataclass
import math
from typing import Tuple

@dataclass
class TwoBodyThermalSystem:
    m1: float
    c1: float
    m2: float
    c2: float
    K: float
    T1_initial: float
    T2_initial: float

    @property
    def C1(self) -> float:
        return self.m1 * self.c1

    @property
    def C2(self) -> float:
        return self.m2 * self.c2

    def derivatives(self, T1: float, T2: float) -> Tuple[float, float]:
        dT1_dt = -(self.K / self.C1) * (T1 - T2)
        dT2_dt = +(self.K / self.C2) * (T1 - T2)
        return dT1_dt, dT2_dt

    def equilibrium_temperature(self) -> float:
        return (self.C1 * self.T1_initial + self.C2 * self.T2_initial) /
            (self.C1 + self.C2)
```

```python

    def rate_constant(self) -> float:
        return self.K * (1.0 / self.C1 + 1.0 / self.C2)

    def analytic_solution(self, t: float) -> Tuple[float, float]:
        Teq = self.equilibrium_temperature()
        lam = self.rate_constant()
        T1 = Teq + (self.T1_initial - Teq) * math.exp(-lam * t)
        T2 = Teq + (self.T2_initial - Teq) * math.exp(-lam * t)
        return T1, T2
```

numerical_methods.py

```python
from __future__ import annotations
from typing import Tuple
from model import TwoBodyThermalSystem

State = Tuple[float, float] # (T1, T2)

def euler_step(system: TwoBodyThermalSystem, state: State, dt: float) -> State:
    T1, T2 = state
    dT1, dT2 = system.derivatives(T1, T2)
    return (T1 + dt * dT1, T2 + dt * dT2)

def heun_step(system: TwoBodyThermalSystem, state: State, dt: float) -> State:
    T1, T2 = state
    dT1_a, dT2_a = system.derivatives(T1, T2)
    T1_pred = T1 + dt * dT1_a
    T2_pred = T2 + dt * dT2_a
    dT1_b, dT2_b = system.derivatives(T1_pred, T2_pred)
    T1_next = T1 + (dt / 2.0) * (dT1_a + dT1_b)
    T2_next = T2 + (dt / 2.0) * (dT2_a + dT2_b)
    return (T1_next, T2_next)

```

```python
def rk4_step(system: TwoBodyThermalSystem, state: State, dt: float) -> State:
    T1, T2 = state

    k1_T1, k1_T2 = system.derivatives(T1, T2)

    T1_2 = T1 + 0.5 * dt * k1_T1
    T2_2 = T2 + 0.5 * dt * k1_T2
    k2_T1, k2_T2 = system.derivatives(T1_2, T2_2)

    T1_3 = T1 + 0.5 * dt * k2_T1
    T2_3 = T2 + 0.5 * dt * k2_T2
    k3_T1, k3_T2 = system.derivatives(T1_3, T2_3)

    T1_4 = T1 + dt * k3_T1
    T2_4 = T2 + dt * k3_T2
    k4_T1, k4_T2 = system.derivatives(T1_4, T2_4)

    T1_next = T1 + (dt / 6.0) * (k1_T1 + 2*k2_T1 + 2*k3_T1 + k4_T1)
    T2_next = T2 + (dt / 6.0) * (k1_T2 + 2*k2_T2 + 2*k3_T2 + k4_T2)
    return (T1_next, T2_next)
```

simulation.py

```python
from __future__ import annotations
from typing import Callable, Dict, List, Tuple
import time

from model import TwoBodyThermalSystem
from numerical_methods import euler_step, heun_step, rk4_step, State

StepFunc = Callable[[TwoBodyThermalSystem, State, float], State]

METHODS: Dict[str, StepFunc] = {
    "euler": euler_step,
```

```python
    "heun": heun_step,
    "rk4": rk4_step,
}

def run_simulation(system: TwoBodyThermalSystem, method: str, t_end: float, dt: float) -> Tuple[List[float], List[float], List[float]]:
    method_key = method.lower().strip()
    if method_key not in METHODS:
        raise ValueError(f"Nepoznata metoda: {method}. Podrzane: {list(METHODS.keys())}")

    step: StepFunc = METHODS[method_key]

    times: List[float] = [0.0]
    T1_list: List[float] = [system.T1_initial]
    T2_list: List[float] = [system.T2_initial]

    t = 0.0
    state: State = (system.T1_initial, system.T2_initial)

    n_steps = int(round(t_end / dt))
    for _ in range(n_steps):
        state = step(system, state, dt)
        t += dt
        times.append(t)
        T1_list.append(state[0])
        T2_list.append(state[1])

    return times, T1_list, T2_list

def final_error_against_analytic(system: TwoBodyThermalSystem, method: str, t_end: float, dt: float) -> Tuple[float, float]:
    _, T1, T2 = run_simulation(system, method, t_end, dt)
    T1_exact, T2_exact = system.analytic_solution(t_end)
```

```python
    return abs(T1[-1] - T1_exact), abs(T2[-1] - T2_exact)

def measure_runtime(system: TwoBodyThermalSystem, method: str, t_end: float,
    dt: float, repeats: int = 10) -> float:
    start = time.perf_counter()
    for _ in range(repeats):
        run_simulation(system, method, t_end, dt)
    end = time.perf_counter()
    return (end - start) / repeats
```

analysis.py

```python
from __future__ import annotations
from typing import Dict, List, Tuple
from model import TwoBodyThermalSystem
from simulation import final_error_against_analytic, measure_runtime

def error_sweep(system: TwoBodyThermalSystem, t_end: float, dts: List[float],
    methods: List[str]) -> Dict[str, List[Tuple[float, float, float]]]:
    out: Dict[str, List[Tuple[float, float, float]]] = {}
    for m in methods:
        rows = []
        for dt in dts:
            e1, e2 = final_error_against_analytic(system, m, t_end, dt)
            rows.append((dt, e1, e2))
        out[m] = rows
    return out

def runtime_sweep(system: TwoBodyThermalSystem, t_end: float, dt: float,
    methods: List[str], repeats: int = 10) -> Dict[str, float]:
    return {m: measure_runtime(system, m, t_end, dt, repeats=repeats) for m in
        methods}
```

scenarios.py

```python
from __future__ import annotations
from typing import Dict, List


def get_scenarios() -> List[Dict]:
    """
    Definicija simulacionih scenarija za analizu toplotne razmjene
    između dva tijela.
    """
    return [

        # Scenario A: Simetrične toplotne mase (C1 = C2)

        {
            "name": "Scenario A: Simetrične toplotne mase (C1 = C2)",
            "m1": 2.0, "c1": 500.0,
            "m2": 1.0, "c2": 1000.0,
            "T1": 80.0, "T2": 20.0,
            "K": 50.0,
            "t_end": 60.0,
            "dt": 0.5,
        },

        # Scenario B1: Velika razlika toplotnih masa (C1 >> C2),
        # tijelo T1 je inicijalno toplije

        {
            "name": "Scenario B1: Velika razlika toplotnih masa (C1 >> C2), T1
                toplije",
            "m1": 2.5, "c1": 500.0,
            "m2": 2.0, "c2": 500.0,
            "T1": 80.0, "T2": 20.0,
            "K": 50.0,
```

```
        "t_end": 60.0,
        "dt": 0.5,
    },

     # Scenario B2: Velika razlika toplotnih masa (C1 >> C2),
    # tijelo T1 je inicijalno hladnije

    {
        "name": "Scenario B2: Velika razlika toplotnih masa (C1 >> C2), T1
           hladnije",
        "m1": 2.5, "c1": 500.0,
        "m2": 2.0, "c2": 500.0,
        "T1": 20.0, "T2": 80.0,
        "K": 50.0,
        "t_end": 60.0,
        "dt": 0.5,
    },

    # Scenario C: Slaba termička veza (mali K)

    {
        "name": "Scenario C: Slaba termička veza (mali K)",
        "m1": 1.0, "c1": 500.0,
        "m2": 1.0, "c2": 500.0,
        "T1": 80.0, "T2": 20.0,
        "K": 5.0,
        "t_end": 200.0,
        "dt": 1.0,
    },

    # Scenario D: Jednake toplotne mase, velika početna razlika temperatura

    {
```

```
        "name": "Scenario D: Jednake toplotne mase, velika početna razlika
            temperatura",
        "m1": 1.0, "c1": 1000.0,
        "m2": 1.0, "c2": 1000.0,
        "T1": 150.0, "T2": 0.0,
        "K": 50.0,
        "t_end": 80.0,
        "dt": 0.5,
    },
]
```